

Rapport rattrapage Big Data - Vincent GERME

I. Le dataset choisi

Récemment j'ai vu passer une nouvelle sur une énorme usine située à La Courneuve, appelée usine Babcock. Elle se serait fait racheter dans un objectif de réhabilitation en espace culturelle énorme.

J'ai trouvée l'idée sympa et je me suis dit pourquoi pas moi.

Je me suis mis dans la peau d'un investisseur ayant un projet similaire et j'ai trouvé un dataset qui agrège toutes les friches répertoriées de France (produit par Cerema).

Forcément comme précisé sur le site de data-gouv, étant donné qu'il s'agit de données recomposées à partir de données locales, on ne trouve pas forcément la même répartition de friches en fonction des territoires.

Mais tout de même, en tant qu'investisseur cela me semble être une véritable mine d'or.

II. Les traitements réalisés

Tout d'abord, lorsque j'observe le dataset, je remarque qu'il y a énormément de colonnes et certaines ne sont même pas remplies.

J'ai commencé par déterminer quelles étaient les colonnes avec un taux de valeurs manquantes à 100%.

J'ai aussi observé de plus près les colonnes qui m'intéressaient, c'est-à-dire le type d'espace (industrielle, logistique etc.), le statut de la friche (si il y a un projet en cours ou non), si le sol est pollué ou si l'espace est occupé ce qui entraînerait des frais et des délais supplémentaires au projet.

J'ai remarqué que parmi ces colonnes il y avait beaucoup de valeurs similaires mais avec des écritures différentes à chaque fois (première lettre en capital, fautes de frappes).

J'ai ensuite fait un grand nettoyage, donc d'abord supprimé les colonnes n'ayant aucune valeur et aussi une étape de normalisation dans les valeurs des colonnes listées plus tôt. J'aurais pu aller plus loin dans le nettoyage des données et faire cette démarche pour chaque colonne du dataset mais j'ai préféré me focaliser sur les colonnes les plus intéressantes.

Pour la partie analyse, il fallait déjà déterminer quel type de friche je recherche.

J'ai donc commencé par faire un tableau mettant en évidence la surface moyenne et médiane en fonction du type de friche.

J'ai établi ensuite un certain nombre de critères de recherche.

Pour le type, c'est sur les friches aéroportuaires, industrielles, logistiques et agro-industrielles que je me suis concentré. Car elle faisait partie des friches proposant les plus grands espaces et que par rapport à mon projet d'investissement elle m'intéressait au vue des coûts de réhabilitation potentiels (cela sort du

cadre de ce devoir) et aussi au vue de mes envies. Je souhaite une surface de minimum 10 000 m² et il faut que la friche soit sans projet en cours ou passé. Ce sont les "candidats".

J'ai trouvé 1442 candidats, parmi ces derniers.

Il y avait 13.8% de chances pour que les friches industrielles soient polluées et 0.4% qu'elles soient occupées, tandis que pour les friches aéroportuaires rien à signaler.

En tant qu'investisseur c'est potentiellement sur une friche aéroportuaire que je vais m'orienter, ça pourrait être sympa un festival de musique sur une ancienne base aérienne.

J'ai ensuite fait une rapide revue de la surface en fonction du statut du site. Et j'ai remarqué que les projets en cours ou passés avaient tendances à être plus gros que les friches sans projets, il faut donc que je me dépêche si je souhaite investir car probablement que ces gros espaces vont être rachetés prochainement.

J'ai ensuite fait une tentative de corrélation entre la taille du terrain et le nombre de bâtiments sur le site, cela a donné une faible corrélation entre ces deux facteurs (0.276). C'est peut être due à la qualité des informations du dataset ou aussi à la complexité juridique de la définition d'une unité foncière (selon la loi une unité foncière doit être contiguë), ce qui fait que des très grandes friches avec des parcelles de terrain non contiguës peuvent avoir plusieurs bâtiments mais ne pas être compté sur la même unité foncière.

Pour finir, j'ai ensuite fait deux histogrammes représentant la répartition des surfaces en fonction du nombre de friches, sur ces deux dernières on remarque une courbe népérienne qui représente bien que plus la surface augmente plus la friche devient rare.

Sur la deuxième j'ai décidé de mettre en évidence la répartition des friches polluées ou occupées toujours en fonction de la surface et l'on remarque que plus un lot est grand moins il a de chance d'être pollué ou occupé.

III. Les résultats observées

En tant qu'investisseur, tout cela me conforte dans mon choix de racheter une lieu énorme comme une friche aéroportuaire. Car elles se font de plus en plus rares, elles sont plus recherchées et elle nécessite généralement moins de coûts et de délais de dépollution et d'expulsion.

IV. Les limites et pistes d'amélioration

Comme évoqué plus tôt mais le nettoyage des données aurait pu être approfondi et la sélection des critères de recherches plus précise.

De plus ça aurait été sympa de faire un mini moteur de recherche avec une carte pour simplifier la vie des investisseurs qui ont le même projet que moi car celle officielle de carto friche n'est pas forcément hyper intuitive.